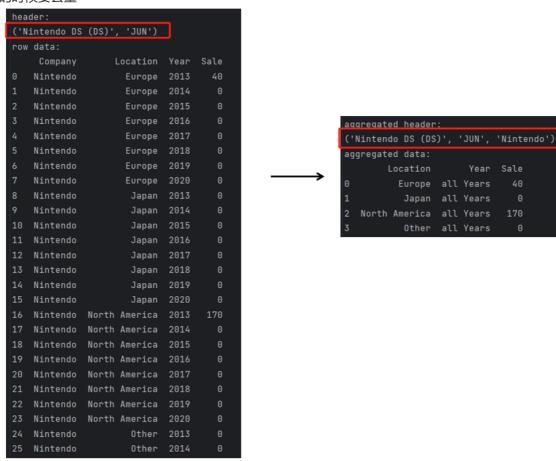
数据处理方式

step1. 枚举header的组合找出全部block data

step2. 对每一个block data,有两种计算insight的方式:

- 1. no breakdown,直接对整个数据
- 2. 设置除最后一列 (Sale) 的每一列为breakdown index, 进行分组和聚合

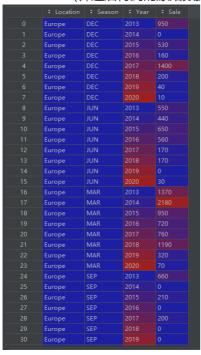
因为最后要生成discription,所以计算前需要先检查主列是否只有一个实体,保证discription里的主语是正确的。如果是的话就提取出来(本质上是将多余的全包含的列提取到header里),这样做会导致insight重复,因为('Nintendo DS(s)', 'JUN', 'Nintendo')这个subspace也会计算出来相同的结果,所以写入的时候要去重



一个例子

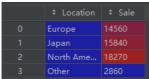
例如对于header:('Nintendo', 'Nintendo 3DS (3DS)')

block data (筛选后得到的原始数据):

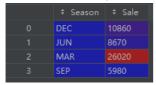


- 1. no breakdown:对整个表格计算insight,这组数据里没计算出insight
- 2. 三组breakdown:

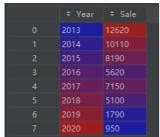
breakdown = 0 (以第一列为主列,分组+聚合):top2



breakdown = 1 (以第二列为主列,分组+聚合): dominance



breakdown = 2 (以第三列为主列,分组+聚合): trend



最后体现在subspace_insight里就是:

因为对header做枚举的时候是对所有可能的情况做了**组合**,在breakdown的时候又考虑了**顺序**,所以这样做完得到的insight是全的。

比如上面的例子里,在筛选('Nintendo', 'Nintendo 3DS (3DS)')过后得到的数据还有四列,做breakdown就是考虑这个区域里的所有列,分别是location-sale、season-sale、year-sale三组对应关系,得到三组insight。